

TYPE DATA


DATA KATEGORIKAL (QUALITATIVE)

M - Male

F - Female

Data Nominal

Data Ordinal





DATA NUMERIKAL (QUANTITATIVE)



Data Numerik terbagi dua:

- Data Diskrit Variabel hasil dari penghitungan, misal : jumlah anak, jumlah pasien dll
- Data kontinyu
 Hasil dari pengukuran, misal : tekanan darah, Hb dll

MISSING VALUES

Missing completely at random (MCAR)

Missing at random (MAR)

Missing not at random (MNAR)

Structurally Missing Data



MISSING COMPLETELY AT RANDOM (MCAR)

- data survei menggunakan subset pertanyaan acak dari daftar yang telah ditentukan sebelumnya.
- data yang diukur dari sensor yang tidak konsisten yang menghasilkan nilai yang hilang

Α	В	C	D
	1	0	1
1	0		1
0		1	0
1	0		1
0	0	1	

MISSING AT RANDOM (MAR)

sensor yang melewatkan pengukuran dalam menit tertentu tetapi merekam data di menit sebelumnya dan menit berikutnya.

Α	В	С	D
1	1	0	
1	0	0	
0	1	1	
1	0	0	1
0	0	1	1

MISSING NOT AT RANDOM (MNAR)

- Missing yang diketahui Tetapi tidak dapat diprediksi
- orang dalam kelompok usia/pendapatan tertentu menolak untuk menjawab berapa banyak kendaraan atau rumah yang mereka miliki

Α	В	С	D
1	1	0	1
1	0	0	1
0	1		0
1	0	0	1
0	0		1

STRUCTURALLY MISSING DATA

 data yang hilang dengan sengaja. Misalnya, survei yang meminta penghasilan dari pekerjaan akan memiliki nilai missing bagi mereka yang tidak memiliki pekerjaan.

Α	В	C	D
1	1	0	1
1	0	0	1
0	1	1	0
1	0	0	1
0			

HANDLING MISSING VALUES

Deleting Rows with missing values

Impute missing values for continuous variable


Impute missing values for categorical variable


Other Imputation Methods




DELETING ROWS WITH MISSING VALUES











Pro & Kontra: menciptakan model yang bagus Kehilangan banyak informasi

IMPUTE MISSING VALUES FOR CONTINUOUS VARIABLE

Kolom yang memiliki data numerik, bisa diganti data yang missing dengan mean, median, modus





Pro:


- Mencegah kehilangan data yang akibat penghapusan baris atau kolom
- Bekerja dengan baik dalam ukuran data yang kecil dan mudah diimplementasikan.

Kontra:

- Bekerja hanya dengan variable kontinyu numerik
- Menyebabkan data leakage

IMPUTE MISSING VALUES FOR CATEGORICAL VARIABLE

 Ketika kolom berisi kategorikal data, missing values bisa direplace dengan data yang paling banyak banyak frekuensinya. Tetapi jika missing valuenya sangat besar, maka bisa diganti dengan kategori baru





Pro:

- Mencegah kehilangan data yang akibat penghapusan baris atau kolom
- Bekerja dengan baik dalam ukuran data yang kecil dan mudah diimplementasikan.
- Mencegah hilang data dengan menambahkan kategori unik

Kontra:

- Bekerja hanya dengan variable data kategori
- Menambahkan fitur baru mungkin menyebabkan model kurang bagus

OTHER IMPUTATION METHODS

Last observation carried forward (LOCF) method

```
1 data["Age"] = data["Age"].fillna(method='ffill')
```

interpolation of the variable

```
1 data["Age"] = data["Age"].interpolate(method='linear', limit_direction='forward', axis=0)
```

SINGLE IMPUTAION

Serial	Gender	Income
1	Female	100
2	Female	NA
3	Male	100
4	Female	300
5	Male	NA
6	Male	200
7	Female	200

Serial	Gender	Income
1	Female	100
2	Female	180
3	Male	100
4	Female	300
5	Male	180
6	Male	200
7	Female	200

SINGLE IMPUTATION

Serial	Age	Death reason
1	60	Covid-19
2	64	NA
3	42	Heart attack
4	67	Covid-19
5	80	NA
6	32	Cancer
7	35	Cancer
8	45	Cancer
9	88	NA
10	33	Heart attack


Shahidul Islam Khan & Abu Sayed Md Latiful Hoque, SICE: an improved missing data imputation technique, Journal of Big Data



OUTLIERS,
CHECKING
AND
HANDLING
THEM

OUTLIERS


- Sebuah data poin yang terletak jauh dari letak data poin yang lain
- Outlier terjadi karena Variability data atau error data recorded



CHECK OUTLIERS

Box plot (matplotlib/seaborn)


```
import matplotlib.pyplot as plt
plt.boxplot(sample, vert=False)
plt.title("Detecting outliers using Boxplot")
```



CHECK OUTLIERS

Z-scores


```
import numpy as np
outliers = []
def detect_outliers_zscore(data):
    thres = 3
    mean = np.mean(data)
    std = np.std(data)
    # print(mean, std)
    for i in data:
        z score = (i-mean)/std
        if (np.abs(z_score) > thres):
            outliers.append(i)
    return outliers# Driver code
sample_outliers = detect_outliers_zscore(sample)
print("Outliers from Z-scores method: ", sample_outliers)
```



CHECK OUTLIERS

Inter Quartile ranges

```
outliers = []
def detect_outliers_iqr(data):
    data = sorted(data)
    q1 = np.percentile(data, 25)
    q3 = np.percentile(data, 75)
    # print(q1, q3)
    IQR = q3-q1
    lwr bound = q1-(1.5*IQR)
    upr_bound = q3+(1.5*IQR)
    # print(lwr bound, upr bound)
    for i in data:
        if (i<lwr_bound or i>upr_bound):
            outliers.append(i)
    return outliers# Driver code
sample_outliers = detect_outliers_iqr(sample)
print("Outliers from IQR method: ", sample_outliers)
```



HANDLING OUTLIERS

Trimming/Remove the outliers

```
# Trimming
for i in sample_outliers:
    a = np.delete(sample, np.where(sample==i))
print(a)
# print(len(sample), len(a))
```

Quantile based flooring and capping


```
# Computing 10th, 90th percentiles and replacing the outliers
tenth_percentile = np.percentile(sample, 10)
ninetieth_percentile = np.percentile(sample, 90)
# print(tenth_percentile, ninetieth_percentile)b = np.where(sample<tenth_percentile, tenth_percentile, sample)
b = np.where(b>ninetieth_percentile, ninetieth_percentile, b)
# print("Sample:", sample)
print("New array:",b)
```

HANDLING OUTLIERS

Mean/Median imputation

```
median = np.median(sample)# Replace with median
for i in sample_outliers:
    c = np.where(sample==i, 14, sample)
print("Sample: ", sample)
print("New array: ",c)
# print(x.dtype)
```

```
plt.boxplot(c, vert=False)
plt.title("Boxplot of the sample after treating the outliers")
plt.xlabel("Sample")
```



REFERENCES & THANK YOU

- https://towardsdatascience.com/missing-value-handling-missing-data-types-a89c0d81a5bb
- https://towardsdatascience.com/7-ways-to-handle-missing-values-in-machine-learning-la6326adf79e
- https://www.analyticsvidhya.com/blog/2021/05/detecting-and-treating-outliers-treating-the-odd-one-out/